

주제2 . 기상 및 소방 데이터를 활용한 119 신고 건수 예측

분류-회귀 앙상블을 적용한 119 신고 건수 예측

공모분야	안전방재	참가번호	250276
팀명	대충맑음	대표자명	송현정

1. 분석 배경 및 목표

기후 변화로 인한 폭염, 집중호우, 태풍과 같은 극한 기상 현상이 반복되면서 도시 안전을 위협하는 긴급 상황이 증가하고 있다. 동시에 고령화와 도시 밀집화로 인해 119 신고 수요는 지역별, 시간대별로 예측하기 어려운 양상을 보이며 급증하고 있다. 특히 단기간에 수요가 폭증하는 재난 상황에서는 소방 인력과 장비의 부족으로 신속한 대응이 어려워지고, 이는 시민의 생명과 안전에 직접적인 영향을 미치게 된다. 기존의 정적인 인력 배치나 운영 방식만으로는 이러한 수요 변동성에 효과적으로 대응하기 어려우며, 날씨나 시간 등 외부 요인을 반영한 사전 예측 기반의 자원 운용 전략이 요구된다. 이에 따라 기상 정보와 소방 데이터를 연계하여 119 신고 수요를 예측하는 체계의 필요성이 대두되고 있다.

본 과제는 기상 데이터와 소방 신고 데이터를 활용하여 특정 날짜와 지역의 119 신고 건수를 예측하는 것을 목표로 한다. 날씨, 요일, 공휴일, 재난 특보 등 다양한 외부 요인을 반영해 신고 수요의 시간적·공간적 패턴을 정량적으로 포착하고자 한다. 이를 통해 119 자원의 사전 배치, 재난 대비 계획 수립, 효율적인 인력 운영 등 공공안전 서비스의 전략적 의사결정에 기여할 수 있는 데이터 기반의 예측 체계를 구축하고자 한다.

2. 분석 데이터 및 전처리


기상청의 날씨 정보와 119 신고 데이터를 기반으로, 특정 일자와 지역의 신고 유형별 건수를 예측할 수 있는 학습 데이터를 구축하였다. 제공된 두 데이터는 날짜와 주소를 기준으로 병합 및 재구성되었으며, 분석 목적에 맞춰 다음과 같은 전처리 과정을 수행하였다.

2.1 변수 통합 및 데이터 구조 정리


먼저, 지역 구분 강화를 위해 행정구(address_gu)와 세부 주소(sub_address) 정보를 결합한 새로운 주소 변수(full_address)를 생성하였다. 신고 유형은 '구급', '구조', '기타화재'의 세 가지로 단순화하였고, 불필요한 변수는 제거하였다.

2.2 데이터 구조 확장

원본 데이터는 일자·지역별 신고 건수를 하나의 값으로 제공하고 있으나, 신고 유형별 패턴을 확인한 결과, '구급'은 비교적 안정적인 분포를 보인데 반해, '구조'와 '기타화재'는 특정 시점에서 신고 건수가 급등하는 등 높은 변동성을 나타내는 경향이 있었다. 이에 따라 전체 신고 건수를 단일 값으로 예측하는 방식보다는, 세 가지 유형(구급, 구조, 기타화재)으로 나누어 각각의 수요 특성을 반영하는 것이 예측 성능 향상에 더 효과적이라고 판단하였다.



[그림 1] 신고 건수 분포



[그림 2] 카테고리별 신고 건수 변화

또한 대부분의 날짜-지역 조합에서 신고 건수가 0~2건에 집중되어 있고, 일부 조합에서는 특정 유형의 신고만 존재하는 경우도 확인되었다. 이러한 불균형은 학습 과정에서 유형별 수요 특성을 왜곡하거나, 모델이 '신고 없음'을 제대로 인식하지 못하는 문제로 이어질 수 있다. 이를 해결하기 위해 전체 데이터를 재구성하여, 날짜-지역 조합마다 세 가지 신고 유형이 모두 포함되도록 구조를 확장하였다. 즉, 특정 날짜-지역에 해당 유형의 신고 건수가 존재하지 않더라도, 해당 행을 생성하고 건수를 0으로 채워 넣었다. 이러한 확장 방식은 모델이 실제 신고뿐만 아니라 '미발생 상황'도 함께 학습할 수 있게 하여, 예측 안정성과 범용성을 확보하는 데 기여하였다.


2.3 결측치 처리

학습 데이터에서는 `hm_max(3,056)`, `hm_min(3,056)`, `rn_day(255)`, `ws_max(141)`, `ws_ins_max(141)`, `ta_max(133)`, `ta_min(133)`, `ta_max_min(133)` 순으로 기상 변수에서 결측치가 관측되었고, 검증 데이터에서도 유사한 결측 패턴이 확인되었다.

결측치는 '거리 역가중 보간법(IDW, Inverse Distance Weighting)'을 적용하여 처리하였다. 이는 동일 날짜 기준으로 결측이 발생한 관측소에 대해 인접 관측소들의 측정값을 거리의 역수를 가중치로 평균하는 방식이다. 단순히 동일 행정군·구 평균을 사용하는 경우, 관측소 간의 실제 물리적 거리를 반영하지 못하는 문제가 있으며, 때로는 같은 행정구 내의 관측소보다 인접 행정군·구의 관측소가 지리적으로 더 가까운 경우도 있다. 이러한 공간적 불연속성을 해소하기 위해, 실제 거리 기반의 IDW 보간법을 선택하였다. 이를 통해 지역 간 기상 연속성을 보다 정밀하게 반영하였고, 전반적인 결측 문제를 효과적으로 해소할 수 있었다.

2.4 이상치 처리

전체 데이터를 시계열로 확인한 결과, 2020년 9월 3일에 신고 건수가 이례적으로 급증한 현상이 관측되었다. 해당 날짜는 부산시가 태풍 '마이삭'의 직접적인 영향권에 들었던 날로, 구조와 기타화재 신고가 특히 평소 대비 현저히 높은 수준으로 나타났다. 이는 데이터 오류나 입력 실수가 아닌, 실제 기상 재난으로 인한 수요 급등 현상으로 판단되었다. 따라서 이상치를 제거하거나 조정하지 않고 그대로 유지하되, 일반적인 일상 패턴과 구분할 수 있도록 해당 날짜를 식별하는 플래그 변수(`is_disaster`)를 추가하였다. 이를 통해 모델이 자연재해 등 비정상적 급증 상황을 인지하고, 극단값에 대한 민감도를 조절할 수 있도록 하였다.




[그림 3] 일자별 신고 건수 이상치

3. 분석 방법

3.1 피쳐 엔지니어링

정확한 예측을 위해 날짜, 기상, 신고 이력 등 다양한 정보를 바탕으로 파생 변수를 설계하였다. 개별 기상 변수와 신고 건수 간 Spearman 상관계수가 대부분 0.15 미만으로 낮게 나타나 단일 변수의 예측력은 제한적이었다. 이에 따라 기상 변수 간 조합, 시계열 누적, 범주화 등 복합적 의미를 반영한 파생 변수를 다수 도출하였다.



[그림 4] 신고 건수와 기상 변수 간 상관관계

• 날짜 및 시간 변수

기본적으로 월(month), 연도(year), 요일(dayofweek) 정보를 추출하고, 주말 여부(is_weekend), 공휴일 여부(is_holiday), 주말과 공휴일이 동시에 해당되는 경우를 나타내는 플래그(is_holiday_weekend)를 추가하였다. 또한 요일은 주기적인 패턴을 가지므로, 단순 범주형 처리 외에도 삼각 변환을 적용하여 요일 간 순환성을 반영하였다.

• 기상 및 날씨 변수

날씨의 영향을 정교하게 반영하기 위해 다양한 기상 변수의 조합 및 시계열 기반 파생 변수를 구성하였다. 일 강수량은 구간화하여 5단계 범주형 변수(rn_day_bin)로 만들고, 비의 유무를 나타내는 플래그(is_rainy)도 함께 생성하였다. 또한 전일까지 3일간의 누적 강수량(rn_day_3d_sum)을 계산하여 강수 지속성에 따른 수요 변화를 고려하였다. 이외에도 기온과 습도 조합을 바탕으로 체감온도(apparent_temp), 불쾌지수(discomfort_index), 순간 최대 풍속과 최대 풍속의 비율로 돌풍 계수(wind_gust_factor)를 도출하였다.

- 기상 특보

기상 특보 중에서도 신고 수요에 직접적인 영향을 줄 수 있는 태풍 경보에 집중하여 피처를 구성하였다. 기상청 특보 데이터에서 '태풍' 및 '경보' 조건을 모두 만족하는 항목만 필터링하였고, 해당 특보가 발효된 날짜뿐만 아니라 그 다음날까지 고려하여 플래그(is_typhoon_warning)를 생성하였다. 이는 태풍 경보가 밤시간대에 발효되어 다음날 새벽까지 영향이 지속되는 경우를 고려한 것이다.

- 과거 신고 이력 기반 변수

수요 예측의 기초가 되는 과거 패턴을 반영하기 위해, 전년도 동일 날짜를 기준으로 한 5일 및 7일 이동 평균(call_count_전년도_5일_평균, call_count_전년도_7일_평균)을 계산하였다. 이를 통해 시기적 유사성을 반영하고, 계절성과 반복 패턴을 학습할 수 있도록 하였다. 단, 2020년의 경우 전년도 이력이 존재하지 않기 때문에 해당 데이터에 대해서 플래그(has_prev_year_data)를 생성하여 학습 시 결측 여부를 명시적으로 전달하였다. 이는 데이터 누락이 예측에 미치는 영향을 완화하고자 한 조치이다.

3.2 모델링 및 학습 전략

신고 건수 예측을 위한 모델링 과정에서는 다양한 구조의 모델을 실험적으로 구성하여 비교 분석을 수행하였다. 단순히 모델 구조만을 변경하는 데 그치지 않고, 입력 변수 구성, 스케일링 방식, 결측치 처리 방법 등에 대해서도 여러 방안을 적용해보며 예측 성능에 미치는 영향을 다각도로 검토하였다. 특히 파생 변수 조합이나 기상 특보 및 클러스터링 정보의 활용 여부에 따라 예측 결과가 크게 달라지는 점을 고려하여, 변수 설계와 전처리 전략 또한 실험의 주요 축으로 포함하였다. 이러한 과정을 통해 각 모델의 성능과 해석 가능성, 일반화 수준을 종합적으로 비교하고자 하였다.

■ 실험 모델

- 딥러닝 기반 회귀 모델

log1p 변환된 타겟 값을 예측하는 다층 퍼셉트론(Multilayer Perceptron) 구조로, Dense 층과 Dropout, BatchNormalization을 결합하여 구성하였다. 입력 변수는 정규화를 위해 StandardScaler로 스케일링하였으며, EarlyStopping과 학습률 감소 콜백을 적용하여 과적합을 방지하였다.

- LightGBM 기반 회귀 모델

트리 기반의 LGBM 회귀 모델을 활용하였으며, 사전 학습된 스파이크 분류 모델의 예측 확률을 가중 변수로 활용하는 구조도 함께 실험하였다. 변수 중요도 기반 해석이 가능하다는 장점이 있으며, 파생 변수 조합에 따른 민감도를 파악하기에 유용하였다.

- 2-Stage 회귀 모델 (스�파이크 분기)

신고 급증일에 해당하는 샘플을 탐지하기 위해 CatBoostClassifier 기반의 스파이크 분류 모델을 먼저 학습한 후, 해당 예측 결과에 따라 회귀 모델을 분기 적용하는 구조를 설계하였다. 분류 모델은 SMOTE 기반 오버샘플링을 통해 불균형 보정을 수행하였으며, 회귀 모델은 $\sqrt{\text{변환된 타겟 값}}$ 을 예측한 후 제곱 복원을 통해 원래 스케일로 변환하였다.

- HistGradientBoosting 기반 회귀 모델

Poisson 손실을 기반으로 한 트리 모델 HistGradientBoostingRegressor를 적용하였으며, 지역 변수는 연도별 누적 타겟 인코딩을 통해 수치화하였다. 시간 파생 변수(요일, 월, 계절 등) 및 기상 요소들을 입력 피처로 사용하였고, 예측값은 정수 반올림을 통해 신고 건수 형태로 복원하였다. 해당 모델은 독립적인 실험 모델로서 최종 제출에는 포함되지 않았다.

■ 최종 제출 모델 (분류-회귀 앙상블 구조)

119 신고 건수 데이터는 대부분 0~2건의 낮은 수요에 집중되어 있으나, 재난이나 특이 상황에서는 단기간에 10건 이상으로 급증하는 등 분포의 왜도가 매우 크고, 극단값의 존재 여부에 따라 예측 안정성이 크게 달라진다. 단일 회귀 모델로는 이러한 수요 구조 전반을 동시에 안정적으로 반영하기 어려웠으며, 특히 극단값이 소수에 불과함에도 평균 예측값이 왜곡되는 문제가 발생하였다. 이러한 한계를 극복하기 위해, 신고 건수의 발생 유무와 수준을 먼저 분류로 판단한 후, 그 결과를 회귀 예측에 활용하는 **분류-회귀 앙상블 구조**를 채택하였다.

1단계에서는 신고 건수를 0건, 1~5건, 6건 이상의 세 구간으로 나누어 다중 클래스 분류 문제로 정의하고, CatBoostClassifier를 학습하였다. CatBoost는 범주형 변수 처리에 특화되어 있어 별도의 인코딩 없이도 정확한 학습이 가능하고, 클래스 불균형 완화를 위한 자동 가중치 기능을 지원하여 본 과제의 데이터 구조에 적합하다. 또한 시계열 데이터를 안정적으로 처리할 수 있으며, 예측 결과를 각 클래스별 확률 값으로 출력할 수 있다는 점에서 회귀 모델과의 연계성이 뛰어나다. 학습 과정에서는 TimeSeriesSplit을 적용해 데이터 누수를 방지하고, 클래스별 비율에 따른 가중치를 부여하여 학습 안정성을 높였다. 예측 결과는 각 클래스에 속할 확률 값으로 출력되며, 이는 회귀 단계의 주요 입력 피처로 활용되었다.

2단계 회귀 모델은 분류 결과로 얻은 클래스 확률 값(bin_prob)과 수치형 파생 변수를 결합하여 구성하였다. 수요 급증 가능성을 사전에 반영한 상태에서 정량 예측을 수행함으로써, 저수요와 고수요 상황을 모두 정밀하게 반영하고자 하였다. 입력 변수는 수치형 중심으로 구성하였는데, 이는 1단계에서 이미 범주형 정보가 반영되었기 때문에 회귀 단계에서는 연속 변수의 정량 조정 효과가 더 중요하다고 판단했기 때문이다. 모델은 AutoML 기반의 FLAML을 통해 최적 구조를 자동 탐색하였으며, 타겟은 로그 변환하여 분포의 정규성을 확보한 뒤 예측 결과를 지수 복원, 음수 제거, 반올림 처리하여 실제 신고 건수로 복원하였다. 해당 구조는 극단값 감지와 수요 안정성 예측이라는 두 가지 목적을 모두 충족함으로써 최종 제출 모델로 선정되었다.

4. 결과 및 검증

최종 제출한 분류-회귀 앙상블 모델은 분포 왜도와 수요 급등 구간을 동시에 반영하는 구조로 설계되었으며, 공모전 평가 기준에 따라 진행된 외부 검증에서 **RMSE 1.05**의 성능을 기록하였다. 이는 극단값을 포함한 실제 신고 건수 분포를 효과적으로 반영했음을 보여주는 결과로, 단순 회귀 모델 대비 높은 정밀도를 확보한 것으로 해석할 수 있다.

참가번호 250276의
RMSE는 1.05입니다.

내부 평가에서도 Out-of-Fold 기준 분류 정확도는 약 81% 수준을 기록하였으며, 회귀 예측 결과 역시 log1p 변환 기반의 예측과 FLAML의 자동 모델 최적화를 통해 안정적인 성능을 보였다. 특히 다수의 샘플이 0건에 집중되어 있는 비대칭 분포 구조에서, 예측값이 평균에 쏠리는 현상을 억제하고 저수요와 고수요 영역 모두에서 균형 잡힌 추정이 가능했다.

분류 단계에서 도출된 클래스별 확률 값은 실제 신고 건수와 뚜렷한 상관관계를 보였으며, 이를 회귀 입력으로 활용함으로써 분포적 왜곡을 줄이고, 해석 가능한 예측 근거도 확보할 수 있었다. 또한 태풍 경보, 누적 강수량, 전년도 이력 등의 변수는 고신고 구간을 구분하는데 기여도가 높은 것으로 확인되었다.

이러한 결과는 시간·날씨·과거 패턴 등 다양한 요인이 복합적으로 작용하는 수요 예측 문제에 있어, 분류 기반의 구조적 사전 판단과 수치 기반의 정량 보정이 효과적으로 결합될 때 높은 예측 성능을 달성할 수 있음을 시사한다.

5. 활용 방안

본 과제에서 구축한 예측 모델은 기상 관측자료와 119 신고 데이터를 융합하여, 일 단위로 특정 지역의 신고 건수를 예측하는 구조로 설계되었다. 외부 평가 기준 RMSE는 약 1.05 수준으로, 실제 신고 건수의 변동성을 일정 부분 반영할 수 있는 성능을 확보하였다. 완벽한 수치 예측은 어렵지만, 특정 기상 조건에서 119 신고가 급증하는 경향성을 사전에 포착할 수 있다는 점에서, 예측 기반의 선제적 대응 체계를 마련하는 데 유용한 기반 자료로 기능할 수 있다. 특히 기온 상승, 집중호우, 태풍 접근 등과 같은 고위험 기상 조건 하에서, 신고 건수가 어느 정도 수준으로 증가할지를 사전에 파악할 수 있다면, 단순 대응을 넘어선 전략적 자원 운영이 가능해진다.

예측 모델은 다양한 실무 영역에서 적용 가능하다. 먼저, 예측 결과를 기반으로 고위험 기상 특보 발효 시기에 사전 배치 가능한 소방 인력·장비의 우선순위를 도출할 수 있다. 특정 날짜와 지역에서 신고 수요가 증가할 가능성이 높은 경우, 해당 지역에 소방차, 구급차, 구조 인력을 선제적으로 이동시키는 계획 수립이 가능하며, 평상시에는 과도한 자원 운영을 줄이면서도 위험 상황에서는 효율적으로 대응할 수 있는 유연한 운용 전략을 마련할 수 있다.

둘째, 지역 단위 자원 분산 배치에도 기여할 수 있다. 예측 결과가 행정구 또는 소방서 관할 구역 단위로 제공되면, 신고 수요가 과중될 것으로 예상되는 지역은 미리 인근 관할의 여유 자원을 활용하거나, 광역 단위 자원 공유 체계를 활성화하는 등 실시간 대응 역량을 강화할 수 있다. 특히 출동 차량이나 병상, 응급 인력 배분을 고려할 때, 수요 예측 정보를 반영하면 자원의 과소·과다 배치를 줄이고 대응 효율을 높일 수 있다.

셋째, 사고 유형별 대응 전략 수립에도 응용할 수 있다. 기상 요소와 신고 유형 간의 상관관계를 분석함으로써, 열사병, 익수, 전기화재, 빗길 교통사고 등 특정 기후 조건에서 발생 가능성이 높은 사고 유형에 대해 맞춤형 대응 계획을 수립할 수 있다. 예컨대 고온·고습 조건에서는 폭염 관련 질환 대응 인력을 증원하고, 강수량이 많은 기간에는 구조나 배수 관련 장비를 사전 배치하는 식의 대응 전략이 가능해진다.

더 나아가, 본 모델은 재난 대응 시뮬레이션의 기반 자료로도 활용 가능하다. 다양한 기상 변화 시나리오에 따른 신고 수요 변화 예측을 통해, 특정 재난 발생 시의 자원 부족 리스크를 사전에 시뮬레이션하고, 이에 맞춘 훈련 시나리오를 설계하는 것이 가능하다. 또한 예측 결과는 연간 소방 운영 계획, 계절별 근무조 편성, 대응 체계 수준 설정 등 중장기 전략 수립에도 기초자료로 활용될 수 있다.

다만 본 과제에서 활용한 데이터는 '일 단위'로 제공되어, 시간대별 신고 패턴이나 출근·야간 시간대와 같은 세부 시계열 특성을 충분히 반영하지는 못했다. 향후 시간 단위의 신고 및 기상 데이터가 확보된다면, 출동 수요가 집중되는 고위험 시간대를 보다 정밀하게 포착할 수 있으며, 이에 따라 예측 모델의 민감도와 실효성은 더욱 향상될 것으로 기대된다.

궁극적으로 본 모델은, 정량적 예측 결과를 실시간 의사결정에 활용하는 기반을 제공함으로써, 데이터 기반의 스마트 소방행정과 재난 대응 역량 고도화를 위한 출발점이 될 수 있다.